

## Sesiones 1 a 3: TEORÍA DE ERRORES

---

### Objetivos

---

1. Introducir y comprender los objetivos del Álgebra y Cálculo Numérico.
2. Conocer qué es una aproximación y en qué consiste un error, determinando los distintos tipos de errores en función del origen que tengan.
3. Asumir que los únicos errores que pueden controlarse son los de truncamiento y redondeo.
4. Comprender los conceptos de exactitud y precisión de una aproximación, observando sus similitudes y diferencias.
5. Conocer y trabajar los conceptos de error absoluto y error relativo de una aproximación.
6. Ver cómo afectan las operaciones a los errores absoluto y relativo.
7. Determinar cuántas cifras decimales exactas tiene una aproximación dada.
8. Comprender el concepto de cifra significativa y utilizarlas en las aproximaciones.
9. Distinguir entre aproximación por truncamiento y aproximación por redondeo, utilizando cada una de ellas correctamente.
10. Entender cómo se obtiene la representación en punto flotante de un número y de qué partes consta dicha representación.
11. Tener en consideración las dificultades que aparecen al realizar operaciones con aproximaciones y tener en cuenta cómo afectarán en los resultados posteriores.
12. Determinar la condición y estabilidad de una expresión o método.
13. Realizar aproximaciones mediante aritmética de un determinado número de cifras.
14. Conocer algunos de los principales problemas computacionales que llevan a errores significativos en las aproximaciones obtenidas al realizar operaciones.



# Contenidos

---

## 1. Objetivos del Álgebra y del Cálculo Numérico

**Análisis Numérico:** obtención de soluciones aproximadas (o aproximaciones) y análisis de errores cometidos al considerar dichas aproximaciones:

- Teoría de errores: estimación del error en una aproximación, comportamiento de los errores al operar con aproximaciones, ... (Análisis del error).
- Procedimientos para obtener soluciones aproximadas de ecuaciones algebraicas, de sistemas de dichas ecuaciones, de autovalores... (Álgebra Numérica).
- Aproximación de funciones y operadores: aproximar funciones y operadores utilizando familias de funciones y operadores, respectivamente, cuyas propiedades y comportamiento son conocidos (Cálculo numérico).
- Procedimientos para obtener soluciones aproximadas de problemas de Análisis Matemático: cálculo aproximado de integrales y derivadas, resolución aproximada de ecuaciones diferenciales o de problemas de Cauchy... (Cálculo numérico).

**¿Cuándo lo necesitamos?:** Ante la imposibilidad de conocer una determinada cantidad o una solución exacta, se requieren soluciones aproximadas con un número finito de cifras decimales.

- Sin aproximaciones no podrían calcularse volúmenes ni áreas en los que interviniesen esferas o círculos.
- Al resolver sistemas de ecuaciones que corresponden a medidas en el mundo físico, ni sus soluciones ni sus datos pueden medirse hasta el último decimal.

**Aproximación:** valor erróneo que se da como solución de un problema. También se la denomina **solución aproximada**.

Habitualmente se usan dos o tres cifras decimales para dar aproximaciones de nuestras mediciones, aunque a veces se necesita un mayor número de cifras decimales porque el error que se comete en los resultados de operaciones con números aproximados va aumentando. Por tanto, debe determinarse el grado de error cometido y controlar su crecimiento.

**Método numérico:** algoritmo para obtener solución aproximada (a veces exacta):

- Iterativo: aproximación en paso  $k + 1$  a partir de la calculada en paso  $k$ .
- Recursivo: aproximación en paso  $k + 1$  a partir de al menos dos aproximaciones obtenidas con anterioridad.

**Estudio de un método numérico:** Consiste en determinar una medida para los siguientes dos elementos que los caracterizan:

- **Convergencia:** las aproximaciones obtenidas en cada etapa tienen como límite a la solución del problema. Depende solo del algoritmo y no del equipo.
- **Coste computacional:** corresponde al número de operaciones que se han de realizar para que el algoritmo dé una respuesta. Puede estimarse el coste computacional por término medio o en el peor caso. La primera opción corresponde a considerar por ejemplo los `if` con una probabilidad de ocurrencia de  $1/2$  mientras que la otra corresponde a considerar todas las operaciones que deberían llevarse a cabo, teniendo en cuenta que si el número de operaciones depende de una elección, siempre consideraremos que se ha llevado a cabo la elección que conlleve más cálculos. Depende solo del algoritmo y no del equipo.  
El coste computacional también puede interpretarse alternativamente como la capacidad de memoria que necesita el equipo para almacenar los datos iniciales, los resultados intermedios y los datos finales.
- **Tiempo computacional:** corresponde al tiempo que tarda el algoritmo en ejecutarse para dar la solución aproximada del problema. Depende del algoritmo y del equipo en que se ejecuta (ya que dependiendo de la capacidad y velocidad del equipo, este tiempo podrá disminuir o aumentar).
- **Eficiencia:** el tiempo que tarda en dar una respuesta aceptable en función de los datos introducidos y de la precisión pedida.

Aunque el Análisis Numérico está basado, en parte, en la capacidad y velocidad de cálculo de los ordenadores, debe tenerse en cuenta que la bondad de un método numérico no debe depender del equipo utilizado. Es por eso que, aunque la eficiencia de dos métodos puede compararse mediante su tiempo computacional en un mismo equipo, lo habitual es determinar la eficiencia de un método con independencia del equipo empleado. Para ello, se utilizan el coste computacional y la velocidad de convergencia del método, los cuales dependen tanto de la naturaleza como del tamaño de los datos de entrada (siendo controlable la última característica).

## 2. Tipos de errores en aproximaciones numéricas

1. **Error experimental:** por la propia formulación del problema real a resolver (datos obtenidos con mediciones u observaciones empíricas). Ejemplo: determinación empírica de constantes como el número  $\pi$ , el número  $e$  o la constante de Planck.
2. **Error de modelización:** modelo matemático nunca coincide con realidad, solo explica su comportamiento. Mejor explicación (aproximación) cuantos más datos se conozcan. Ejemplo: modelos atómicos o movimiento de cuerpos celestes.
3. **Error de truncamiento:** número de iteraciones realizadas en un método numérico lleva a diferentes aproximaciones de la solución, cada una con su propio error. Ejemplo: digitalización de imágenes o representación gráfica de funciones en calculadoras y ordenadores.

4. **Error de redondeo:** imposible trabajar con cantidad infinita de cifras (ni usando ordenadores ni nuestra mente). Al determinar límite de cifras a emplear, se origina el error de redondeo, acumulativo con respecto a las operaciones realizadas. El elevado número de operaciones en un método numérico conlleva delimitar la acumulación de errores para obtener una solución aproximada con el nivel de exactitud y precisión deseado.

Los únicos errores que podemos analizar y controlar (hacer tan pequeños como queramos) son los de truncamiento y de redondeo: los primeros aumentando el número de iteraciones a aplicar y los segundos considerando un mayor número de cifras decimales.

### 3. Exactitud y precisión de una aproximación

**Exactitud:** mide cuán cerca está la aproximación del valor exacto del problema: distancia entre valor exacto y valor aproximado. La validez de la aproximación será mayor cuanto mayor sea su exactitud.

**Precisión:** compara las aproximaciones obtenidas con un mismo método. De este modo, determina si las aproximaciones no se dispersan (a menor dispersión, mayor precisión).

Mientras que la exactitud es una medida cuantitativa de la aproximación considerada, la precisión es una medida cualitativa.

Debe tenerse en cuenta que no es lo mismo equivocarse en una unidad cuando el valor exacto es  $\pi$  (la magnitud del número que estás aproximando es igual que la del error) que cuando el valor exacto es 10.54 millones (en el que la magnitud del número a aproximar es 10 millones de veces que la del error que se está cometiendo). De este modo, la exactitud de ambas aproximaciones sería la misma (pues ambas distan 1 unidad del valor exacto), pero la precisión será mayor para la aproximación de 10.54 millones que para la de  $\pi$ .

**Situaciones que acontecen al usar aproximaciones:**

- Determinar el error cometido en el resultado final de un método numérico en función del error cometido en la aproximación utilizada en los datos.
- Determinar el error que hay que considerar en la aproximación de los datos iniciales para obtener un error final menor que un valor fijado.

Para medir tanto la inexactitud como la imprecisión de una aproximación, se definen el error absoluto y el error relativo de la misma.

### 4. Error absoluto de una aproximación. Cifras decimales exactas

**Definición 1** Si  $x^*$  es aproximación de  $x$ , el **error absoluto** cometido por  $x^*$  es:

$$E_A(x^*) = |x - x^*|.$$

**Nota 2**  $E_A$  mide cuantitativamente la bondad de la aproximación: la exactitud.

**Nota 3** Si se define el error absoluto como  $E'_A(x^*) = x - x^*$ , puede determinarse si la aproximación es mayor o menor que el valor exacto. Si  $E'_A(x^*) < 0$ , la aproximación es **por exceso** ( $x^* > x$ ) y si  $E'_A(x^*) > 0$ , es **por defecto** ( $x^* < x$ ).

**Definición 4** La aproximación  $x^*$  tiene  $p$  **cifras decimales exactas** si:

$$E_A(x^*) \leq 10^{-p}.$$

**Ejemplo 5** Considera la aproximación  $x^* = 6.2$  del número exacto  $x = 6$  y la aproximación  $y^* = 6198$  del número  $y = 6000$ . ¿Cuál de los dos aproximaciones siguientes es más exacta? ¿Cuántas cifras decimales exactas tienen ambas aproximaciones?

La pregunta realizada es equivalente a determinar cuál de las dos aproximaciones tiene un menor error absoluto. Calculemos, pues, el error absoluto de cada una de las aproximaciones:

$$E_A(6.2) = |6 - 6.2| = 0.2 \quad \text{y} \quad E_A(6198) = |6000 - 6198| = 198.$$

Como  $E_A(6.2) \leq E_A(6198)$ , la aproximación más exacta es  $x^* = 6.2$ . Además, ambos errores absolutos satisfacen  $E_A > 10^{-1}$ , por lo que no tienen cifras decimales exactas.

## 5. Error relativo. Cifras significativas

**Definición 6** Si  $x^*$  es una aproximación de  $x$ , se define el **error relativo** cometido por  $x^*$  como el cociente:

$$E_R(x^*) = \left| \frac{x - x^*}{x} \right|.$$

**Nota 7**  $E_R$  mide cualitativamente la bondad de la aproximación: la precisión.

**Nota 8** Para ello, se considera el error absoluto en proporción al número exacto que se pretende aproximar.

**Definición 9** La aproximación  $x^*$  de un número real  $x$  se dice que tiene  $t$  **cifras significativas** si  $t$  es el mayor entero no negativo para el cual:

$$E_R(x^*) = \frac{|x - x^*|}{|x|} < 5 \times 10^{-t}.$$

**Ejemplo 10** Tenemos una aproximación de  $\pi$  y otra del número de Avogadro ( $6.022 \times 10^{23}$ ) ambas con un error absoluto igual a 1 (es decir, con la misma exactitud). ¿Son las dos aproximaciones igual de precisas? Esto equivale a preguntar si tienen el mismo error relativo. Calculemos pues dichos errores. Si denotamos por  $x^*$  y por  $y^*$  a las aproximaciones de  $\pi$  y del número de Avogadro respectivamente:

$$E_R(x^*) = \frac{E_A(x^*)}{|\pi|} = \frac{1}{\pi} \approx 0.318309886 \quad \text{y} \quad E_R(y^*) = \frac{E_A(y^*)}{6.022 \times 10^{23}} \approx 1.66 \times 10^{-24}.$$

Obviamente,  $E_R(x^*) > E_R(y^*)$  por lo que la aproximación  $y^*$  del número de Avogadro es más precisa que la del número  $\pi$ .

El número de cifras significativas es 1 para  $x^*$  y 25 para  $y^*$  puesto que

$$E_R(x^*) \approx 0.318309886 < 0.5 = 5 \times 10^{-1} \quad \text{y} \quad E_R(y^*) \approx 1.66 \times 10^{-24} < 5 \times 10^{-24}.$$

**Ejemplo 11** Considera la aproximación  $x^* = 6.2$  del número exacto  $x = 6$  y la aproximación  $y^* = 6198$  del número  $y = 6000$ . ¿Cuál de los dos aproximaciones siguientes es más precisa? ¿Cuántas cifras significativas tienen ambas aproximaciones?

En el Ejemplo 5, calculamos los errores absolutos de ambas aproximaciones como  $E_A(6.2) = 0.2$  y  $E_A(6198) = 198$ . Ahora procedemos a aplicar la definición de error relativo y obtenemos:

$$E_R(x^*) = \frac{E_A(x^*)}{6} = \frac{0.2}{6} \approx 0.0\hat{3} < 5 \times 10^{-2} \quad \text{y} \quad E_R(y^*) = \frac{E_A(y^*)}{6000} \approx 0.033 < 5 \times 10^{-2}.$$

Observa que  $E_R(y^*) < E_R(x^*)$  y, por tanto, la precisión de la aproximación  $y^*$  es mayor que la de  $x^*$ . Recuerda que cuando estudiábamos el error absoluto y la exactitud, la aproximación más exacta era la de  $x^*$  y no la de  $y^*$ . Debes tener en cuenta que una aproximación puede ser más exacta que otra pero eso no implica que sea también más precisa (ni viceversa).

Finalmente, indicar que en vista de los valores de los errores relativos, ambas aproximaciones tienen 2 cifras significativas. Con este ejemplo, también podemos ver claramente que dos aproximaciones pueden tener el mismo número de cifras significativas pero diferente precisión.

## 6. Límite o cota superior de errores absoluto y relativo

**Definición 12** Dada una aproximación  $x^*$  de  $x$ , se dice que  $\varepsilon > 0$  es un **límite o cota superior** del

- **error absoluto** si  $E_A(x^*) \leq \varepsilon$ .
- **error relativo** si  $E_R(x^*) \leq \varepsilon$ .

**Nota 13** Observa que el número de cifras decimales exactas se obtiene a partir de la menor cota superior del error absoluto de la forma  $10^{-k}$  con  $k \in \mathbb{N} \cup \{0\}$ . Análogamente, el número de cifras significativas se obtiene a partir de la menor cota superior del error relativo de la forma  $5 \times 10^{-k}$  con  $k \in \mathbb{N} \cup \{0\}$ .

**Proposición 14** Una cota superior del error relativo de una aproximación es:

$$\varepsilon = \frac{1}{\text{primera cifra significativa} \cdot 10^{(\text{número de cifras decimales exactas} - 1)}}$$

## 7. Intervalos de confianza

**Definición 15** Sean  $x^*$  una aproximación de  $x$  y  $\varepsilon$  un límite superior de  $E_A(x^*)$ . Se denomina **intervalo de confianza** para  $x$  a  $[x^* - \varepsilon, x^* + \varepsilon]$ .

**Nota 16** El uso de los intervalos de confianza se debe a que, por lo general, no podemos determinar con exactitud el valor del error absoluto de una aproximación. Si no somos capaces de obtener la solución exacta (que es lo que nos pasará normalmente), obviamente no seremos capaces igualmente de obtener el valor exacto del error absoluto cometido, sino que solo podremos obtener un límite superior de dicho error. Dicho límite es el que usaremos para dar un intervalo en el que podemos asegurar que se encuentra la solución exacta del problema.

**Proposición 17** Si  $[a, b] \subset \mathbb{R}$  es un intervalo de confianza para un número  $x$ , entonces la aproximación  $x^* = \frac{a+b}{2}$  tiene acotado su error absoluto por:

$$E_A(x^*) \leq \frac{b-a}{2}.$$

## 8. Errores asociados a las operaciones aritméticas. Fórmula de propagación del error

**Proposición 18** Sean  $x$  e  $y$  dos números reales con aproximaciones  $x^*$  e  $y^*$ , respectivamente. Los siguientes errores se cometen realizando las operaciones básicas:

- $E_A(x^* \pm y^*) \leq E_A(x^*) + E_A(y^*)$ .
- $E_R(x^* \cdot y^*) \leq E_R(x^*) + E_R(y^*)$ .
- $E_R\left(\frac{x^*}{y^*}\right) \leq E_R(x^*) + E_R(y^*)$ .

**Ejemplo 19** Sean las aproximaciones  $x^* = 1.10$  e  $y^* = 0.14$  de los números  $x = 1$  e  $y = \frac{1}{7}$ . Calculemos el error absoluto de la suma  $x^* + y^*$  que es una aproximación de la suma  $x + y$ :

$$E_A(x^* + y^*) = \left| \left(1 + \frac{1}{7}\right) - (1.10 + 0.14) \right| \approx 0.09714.$$

Comparemos este resultado con la suma de los dos errores absolutos de cada aproximación por separado:

$$E_A(x^*) = |1 - 1.10| = 0.10 \quad \text{y} \quad E_A(y^*) = \left| \frac{1}{7} - 0.14 \right| \approx 0.002857$$

$$E_A(x^* + y^*) \approx 0.09714 < 0.102857 \approx E_A(x^*) + E_A(y^*)$$

Observa que el error absoluto que realmente se comete es más pequeño que la cota obtenida con la suma de los errores absoluto. Eso se debe a que la aproximación  $x^*$  es por exceso mientras que la de  $y^*$  es por defecto. Por tanto, los dos errores se compensan parcialmente entre sí al sumar ambas aproximaciones.

**Ejemplo 20** El producto  $x^* \cdot y^*$  de las dos aproximaciones  $x$  e  $y$  es una aproximación del producto  $x \cdot y$ . Calculemos en primer lugar el error relativo del producto  $x^* \cdot y^*$  respecto de  $x \cdot y$ :

$$E_R(x^* \cdot y^*) = \frac{|(1 \cdot \frac{1}{7}) - (1.10 \cdot 0.14)|}{|1 \cdot \frac{1}{7}|} = 0.078.$$

Comparemos este resultado con la suma de los dos errores relativos por separado:

$$E_R(x^*) = \frac{E_A(x^*)}{1} = 0.10 \quad \text{y} \quad E_R(y^*) = \frac{E_A(y^*)}{\frac{1}{7}} \approx 0.02$$

$$E_R(x^* \cdot y^*) = 0.078 < 0.12 = 0.10 + 0.02 \approx E_R(x^*) + E_R(y^*)$$

**Proposición 21** Sean una función  $f : \mathbb{R} \rightarrow \mathbb{R}$  con  $f \in \mathcal{C}^1(\mathbb{R})$  y una aproximación  $x^*$  de  $x$ . Entonces una cota del error absoluto al considerar la aproximación  $f(x^*)$  en lugar de  $f(x)$  viene determinada por la siguiente **fórmula de propagación o de transferencia del error**:

$$E_A(f(x^*)) \leq \max_{z \in I} |f'(z)| \cdot E_A(x^*),$$

siendo  $I$  el intervalo cerrado con extremos  $x$  y  $x^*$ .

**Corolario 22** Sean  $a, b \in \mathbb{R}$  y  $z^*$  una aproximación de  $z$ . Si  $f : \mathbb{R} \rightarrow \mathbb{R}$  está definida como  $f(x) = ax + b$  para cualquier  $x \in \mathbb{R}$ , entonces:

$$E_A(f(z^*)) = |a| \cdot E_A(z^*).$$

**Ejemplo 23** Calculemos el valor de  $a = (\sqrt{3} - 2)^6$ , utilizando la aproximación  $z^* = 1.7$  del número  $z = \sqrt{3}$ . ¿Cuál de las dos expresiones siguientes de  $a$  permiten una aproximación más exacta:

$$1) \left(7 - 4\sqrt{3}\right)^3 \quad 2) \frac{1}{1351 + 780\sqrt{3}} ?$$

Primero probaremos que ambas expresiones anteriores son iguales a la expresión de  $a$ . La primera expresión se obtiene como sigue:

$$a = \left(\sqrt{3} - 2\right)^6 = \left(\left(\sqrt{3} - 2\right)^2\right)^3 = \left(7 - 4\sqrt{3}\right)^3,$$

desarrollando el cuadrado. Para la segunda, lo único que debe hacerse es desarrollar la potencia sexta y racionalizar el numerador como sigue:

$$\begin{aligned} a &= \left(\sqrt{3} - 2\right)^6 = 1351 - 780\sqrt{3} = (1351 - 780\sqrt{3}) \cdot \frac{1351 + 780\sqrt{3}}{1351 + 780\sqrt{3}} \\ &= \frac{(1351 - 780\sqrt{3}) \cdot (1351 + 780\sqrt{3})}{1351 + 780\sqrt{3}} = \frac{1}{1351 + 780\sqrt{3}} \end{aligned}$$

Para comprobar cuál de las dos aproximaciones es más exacta lo que tenemos que hacer es calcular el error absoluto de cada aproximación y ver cuál de las dos tienen menor error absoluto. Para ambos cálculos usaremos el lema de propagación del error como sigue:



- 1) Consideramos la función  $f(x) = (7 - 4x)^3$  que es polinómica y de clase infinito, pudiéndose aplicar el lema de propagación del error. De hecho, se tiene que


$$a = f(z) = f(z^*) \pm E_A(f(z^*))$$

y el valor de  $a$  se puede aproximar por  $f(z^*)$ , siendo el error absoluto cometido igual a  $E_A(f(z^*))$ . La aproximación de  $a$  que estamos teniendo en consideración será  $f(z^*) = f(1.7) = 0.008$ .

El error absoluto que se cometería con esta aproximación sería:

$$E_A(f(z^*)) \leq \max_{x \in [1.7, \sqrt{3}]} |f'(x)| \cdot E_A(z^*).$$

Por tanto, solo nos resta calcular el máximo de la función  $f'$  en  $[1.7, \sqrt{3}]$  y el error absoluto  $E_A(z^*)$ . La función derivada  $f'$  viene dada por la expresión  $f'(x) = -12(7 - 4x)^2$  y la gráfica de la función  $|f'|$  en el intervalo en cuestión es:



donde puede observarse que el máximo se alcanza para  $x = 1.7$ . Por tanto, el valor del máximo es

$$\max_{x \in [1.7, \sqrt{3}]} |f'(x)| = 0.48.$$

Quedaría calcular el error  $E_A(z^*)$  cuyo resultado viene dado por


$$E_A(z^*) = |z - z^*| = |\sqrt{3} - 1.7| \approx 0.0320508 < 0.1.$$

En consecuencia, el error absoluto  $E_A(f(z^*))$  que se comete al calcular  $a$  a partir de la primera expresión sería  $E_A(f(z^*)) \leq 0.048 < 10^{-1}$ . Obviamente, podríamos calcular un valor más ajustado del error absoluto  $E_A(f(z^*))$  tomando el valor que nos ha salido para  $E_A(z^*)$  y no tomando su cota, pero el error absoluto  $E_A(f(z^*))$  seguiría teniendo el mismo límite superior en el caso que nos ocupa.

- 2) Consideramos la función  $g(x) = \frac{1}{1351 + 780x}$ , que es cociente de polinomios y por tanto de clase infinito en  $\mathbb{R} \setminus \{-\frac{1351}{780}\}$  (es decir, donde no se anula el denominador). Por tanto, para calcular el error absoluto que se comete al considerar la aproximación  $g(z^*) = g(1.7) = 0.000373552$  podemos aplicar nuevamente el lema de propagación del error, obteniendo la siguiente expresión:

$$E_A(g(z^*)) \leq \max_{x \in [1.7, \sqrt{3}]} |g'(x)| \cdot E_A(z^*).$$

Solo necesitamos calcular el máximo de  $|g'|$  en el intervalo, pues  $E_A(z^*)$  fue calculado ya previamente. La expresión de  $g'$  viene dada por  $g'(x) = -\frac{780}{(1351+780x)^2}$  y la gráfica de  $|g'|$  en el intervalo estudiado es:



por lo que nuevamente el máximo se alcanza en  $x = 1.7$  con  $|g'(1.7)| \approx 0.000108842$ . En consecuencia, el error absoluto resulta ser:

$$\begin{aligned} E_A(g(z^*)) &\leq \max_{x \in [1.7, \sqrt{3}]} |g'(x)| \cdot E_A(z^*) = |g'(1.7)| \cdot E_A(z^*) \\ &\approx 0.000108842 \times 0.0320508 \approx 3.48848 \times 10^{-6} < 10^{-5}. \end{aligned}$$

En consecuencia, usando la primera expresión obtenemos un error absoluto del orden de  $10^{-1}$ , mientras que el error absoluto cometido con la segunda es del orden de  $10^{-5}$ . Obviamente, la segunda expresión nos permite obtener una aproximación más exacta del valor  $a$ . Observa que también será una estimación más precisa ya que estamos comparando dos aproximaciones del mismo número por lo que la precisión vendrá determinada solo por el error absoluto (numerador en la expresión del error relativo) pues el valor exacto del número a aproximar  $a$  (denominador) es el mismo para ambos cálculos. Es decir, cuando estemos trabajando con aproximaciones del mismo valor, nos basta con considerar la exactitud, la precisión la usaremos cuando tengamos que comparar aproximaciones de valores distintos.

## 9. Error de redondeo

Los errores de redondeo aparecen por la necesidad de manejar cantidades finitas de decimales. Por tanto, todos los números reales (cantidad infinita) deben aproximarse necesariamente usando números racionales. Obviamente, la cantidad de números racionales empleados será mayor cuanto mayor sea el número de decimales considerados. Dado  $x \in \mathbb{R}^+$ , su representación decimal es:

$$x = \sum_{k \in \mathbb{Z}} a_k \cdot 10^k, \quad \text{con } 0 \leq a_k \leq 9 \wedge k \in \mathbb{Z}.$$

**Definición 24** La **parte entera** de  $x$  es la expresión  $\sum_{k \in \mathbb{N} \cup \{0\}} a_k \cdot 10^k = a_n a_{n-1} \cdots a_2 a_1 a_0$

y la **parte decimal** es  $\sum_{k \in \mathbb{N}} a_{-k} \cdot 10^{-k} = a_{-1} a_{-2} \cdots a_{-m+1} a_{-m}$ .

**Ejemplo 25** A continuación, indicamos algunos ejemplos de números aproximados y de su parte entera y su parte decimal:

| Número        | -54.243 | -1.0154 | 0.5555 | 45.50394 |
|---------------|---------|---------|--------|----------|
| Parte Entera  | -54     | -1      | 0      | 45       |
| Parte Decimal | 0.243   | 0.0154  | 0.5555 | 50394    |

## Procedimientos para representar números con $k$ cifras decimales:

1. **Truncamiento** o **tala**: se considera la aproximación  $x_t = a_n \cdots a_1 a_0 a_{-1} \cdots a_{-k}$ .
2. **Redondeo**: la aproximación  $x_r$  se obtiene considerando la  $(k+1)$ -ésima cifra decimal  $a_{-k-1}$ :
  - a) Si  $a_{-k-1} < 5$ , se toma la misma aproximación que en el truncamiento.
  - b) Si  $a_{-k-1} \geq 5$ , se añade una unidad a la  $k$ -ésima cifra  $a_k$  y se tala el número resultante.

**Ejemplo 26** El número  $e$  es un número irracional y como tal necesita de infinitos decimales para expresarlo (y dichos decimales no presentan ningún patrón de repetición). En concreto,  $e = 2,718281828459045\dots$  Para obtener un número que podamos manejar hemos de quedarnos solo con algunos decimales de  $e$ . A continuación, mostramos una tabla en la que se indican aproximaciones por redondeo y por truncamiento de  $e$  teniendo en cuenta el número de decimales considerados:

| Número cifras decimales | 1   | 2    | 3     | 4      | 5       |
|-------------------------|-----|------|-------|--------|---------|
| Por redondeo            | 2.7 | 2.72 | 2.718 | 2.7183 | 2.71828 |
| Por truncando           | 2.7 | 2.71 | 2.718 | 2.7182 | 2.71828 |

**Proposición 27 (Diferencia entre truncamiento y redondeo)** Sea  $x$  un número que es aproximado por  $x_t$  y  $x_r$  mediante truncamiento y redondeo, respectivamente. Entonces se tienen los siguientes errores absolutos:

$$E_A(x_t) = |x - x_t| \leq 10^{-k} \qquad E_A(x_r) = |x - x_r| \leq \frac{1}{2} \cdot 10^{-k}.$$

**Definición 28** Se denomina **error de redondeo**,  $\varepsilon_r$ , al error (absoluto) que se comete al reemplazar un número por su representación con  $k$  cifras decimales (por truncamiento o por redondeo).

**Nota 29** El error de redondeo  $\varepsilon_r$  de una aproximación con  $k$  cifras decimales del número  $x$  es  $E_A(x_t)$  o  $E_A(x_r)$ , dependiendo de haber considerado una aproximación por truncamiento o por redondeo, respectivamente.

**Proposición 30** Las aproximaciones con  $k$  cifras decimales obtenidas tanto por truncamiento como por redondeo tienen, al menos,  $k - 1$  cifras significativas.

## 9.1. Representación en número flotante: Desbordamientos y cancelaciones

Al trabajar con ordenadores, debemos considerar igualmente un factor adicional que nos afectará teóricamente al considerar aproximaciones y trabajar con ellas y que nos pueden llevar a obtener más errores. En primer lugar, hemos de tener en cuenta que el ordenador trabaja con una cantidad finita de datos, por lo que no puede considerar todos los números existentes (que corresponden a una cantidad infinita). Por tanto, todo equipo y software se reduce a trabajar con una cantidad limitada (pero enorme como veremos posteriormente) de números racionales. Efectivamente,

solo se consideran números racionales, por lo que los irracionales son aproximados por expresiones decimales finitas, que corresponden a números racionales. De hecho, un ordenador tampoco es capaz de considerar todos los números racionales finitos, pues por ejemplo aquellos racionales cuya representación es mediante un número decimal periódico corresponden a una cantidad infinita de decimales para representarlos. Estos racionales son representados también por una aproximación usando solo una cantidad finita de decimales. Y es más, tampoco todos los racionales con representación decimal finita pueden ser representados por el ordenador, pues el ordenador tiene determinado un número máximo de decimales a calcular. Por tanto, si el racional tiene más de ese número de decimales, se perderán los decimales que correspondan a la posición posterior a la del mayor decimal que puede calcular.

Estos problemas son los denominados problemas de desbordamiento, que afortunadamente no suelen acontecer si se tiene cuidado con las cantidades utilizadas y todas ellas corresponden a magnitudes similares. Por lo general (aunque no siempre), estos problemas de desbordamiento tienen lugar al utilizar en las mismas operaciones o en el mismo algoritmo números de muy diferente magnitud (esencialmente números muy próximos a cero con números muy grandes en valor absoluto). Al considerar operaciones con tales valores, es extremadamente fácil obtener números que nuestro equipo no va a poder representar. Bastaría con ir realizando la división de un número muy grande por uno muy pequeño (en valor absoluto), con lo que iríamos obteniendo una expresión que tendería a infinito.

Es por ello que pasaremos a indicar cómo trabaja nuestro ordenador (y nuestro software) con los números para tener una mejor comprensión de este problema.

**Representación computacional de los números enteros:** Los números enteros son representados mediante palabras de 32 bits. La forma más sencilla de hacerlo es asignar un bit al signo (0 para signo + y 1 para signo -), mientras que los restantes 31 se destinan a la descomposición del número entero usando las potencias de base

2 con exponentes de 0 a 30:  $\sum_{i=0}^{30} c_i \cdot 2^i$  con  $c_i \in \{0, 1\}$ . Por tanto, el mayor número entero que admite tal representación es  $2^{31} - 1 = 2147483647$ .

Debe tenerse en cuenta que la representación estándar de la IEEE no es exactamente como lo hemos indicado, aunque en la práctica es equivalente a la dada y es por eso que la explicamos de esta manera.

**Representación computacional de los números no enteros:** Se pretende estandarizar la escritura de números en ordenadores para eliminar dependencia de los errores a los equipos. Por tanto, solo hay que estudiar problemas de redondeo y de número de iteraciones. De este modo, el IEEE (Institute for Electrical and Electronic Engineers) estableció como estándar una norma para representar números en los equipos informáticos (y que son seguidas por los fabricantes de ordenadores): Binary Floating Point Arithmetic Standard 754-1985.

La representación en punto (o coma) flotante de un número puede realizarse utilizando precisión simple o precisión doble. Mientras que la primera utiliza 32 bits para representar cualquier número fraccionario, la segunda utiliza 64 (a efectos

prácticos, se utilizan dos palabras de 32 bits para almacenar la información del número como una palabra de 64 bits, de ahí el nombre de precisión doble).

La representación en punto flotante de un número usando precisión simple consta de 32 bits que, de izquierda a derecha, representan:

1. **Signo** del número: primer bit,  $s$ . Si  $s = 0$ , el signo es  $+$  y si  $s = 1$ , es  $-$ .
2. **Característica**,  $c$ : son los 8 bits siguientes y corresponden al exponente (expresado en base 2) de una potencia. Por tanto, corresponde a una combinación de las potencias  $\{2^i | i = 0, \dots, 7\}$ .
3. **Mantisa**,  $m$ : son los últimos 23 bits y guardan la información de la parte fraccionaria (en base 2). Es decir, una combinación de las potencias  $\{2^{-i} | i = 1, \dots, 23\}$ .

De este modo, el número real que representaría el número en punto flotante sería el resultante de la operación  $(-1)^s * 2^{c-128} * (1 + m)$ , donde:

- $c$  ya está expresada en base 10 y, en consecuencia, sería un valor comprendido en el intervalo  $0 \leq c \leq 2^8 - 1 = 255$ . Al restarle 128 al exponente  $c$ , lo que buscamos es obtener tanto exponentes negativos como positivos, ya que los exponentes negativos nos darán números muy próximos a 0 y los positivos, números muy grandes en valor absoluto. De hecho, el nuevo exponente  $c - 128$  se mueve en el intervalo  $[-128, 127]$ .
- $1 + m$  está en base 10. El primer dígito 1 no se almacena, obteniendo un bit más de precisión.

La representación en punto flotante usando precisión doble consiste de 64 bits que, de izquierda a derecha, representan:

1. **Signo** del número: primer bit,  $s$ . Si  $s = 0$ , el signo es  $+$  y si  $s = 1$ , es  $-$ .
2. **Característica**,  $c$ : son los 11 bits siguientes y corresponden al exponente (expresado en base 2) de una potencia. Por tanto, corresponde a una combinación de las potencias  $\{2^i | i = 0, \dots, 10\}$ .
3. **Mantisa**,  $m$ : son los últimos 52 bits y guardan la información de la parte fraccionaria (en base 2). Es decir, una combinación de las potencias  $\{2^{-i} | i = 1, \dots, 52\}$ .

De este modo, el número real que representaría el número en punto flotante sería el resultante de la operación  $(-1)^s * 2^{c-1024} * (1 + m)$ , donde:

- $c$  ya está expresada en base 10 y, en consecuencia, sería un valor comprendido en el intervalo  $0 \leq c \leq 2^{11} - 1 = 2047$ . Al restarle 1024 al exponente  $c$ , el nuevo exponente  $c - 1024$  se mueve en el intervalo  $[-1024, 1023]$ .
- $1 + m$  está en base 10. El primer dígito 1 no se almacena, obteniendo un bit más de precisión.

Teniendo en cuenta la expresión en punto flotante de los números, el menor número que podría obtenerse usando representación en punto flotante, vendría dado por el menor valor posible para la  $c$  y para la  $m$ . En concreto, correspondería a  $c = 0$  y a  $m = 2^{-32}$  para precisión simple o a  $m = 2^{-52}$  para precisión doble:

$$2^{-128} \cdot (1 + 2^{-32}) \approx 2.93874 \times 10^{-39}$$

$$2^{-1024} \cdot (1 + 2^{-52}) \approx 5.562684646268005 \times 10^{-309}.$$

Cualquier número más pequeño que este es considerado por el ordenador como si se tratase de cero y continúa haciendo las operaciones restantes. Esto es lo que llamamos un **desbordamiento por defecto** o **underflow**. Cada vez que despreciamos un término de este tipo, estamos aumentando el error absoluto de la aproximación considerada (aunque puede comprobarse que la magnitud que se desprecia es insignificante). No obstante, puede llevarnos a problemas del tipo siguiente: le estamos pidiendo al ordenador que divida por una expresión no nula, pero como esa expresión es más pequeña (en valor absoluto) que este valor límite, el ordenador interpreta que está dividiendo por cero y no puede continuar.

De manera análoga, podemos considerar el mayor número que puede representarse en punto flotante. Consistirá en tomar los mayores valores posibles tanto para  $m$  como para  $c$ . En concreto, correspondería a considerar  $c = 255$  y  $m = \sum_{i=1}^{32} 2^{-i}$

para precisión simple y  $c = 2047$  y  $m = \sum_{i=1}^{52} 2^{-i}$  para multiplicidad doble:

$$2^{127} \cdot (1 + m) \approx 2^{127} \cdot 2 \approx 3.4028 \times 10^{38}.$$

$$2^{1023} \cdot (1 + m) \approx 2^{1023} \cdot 2 \approx 1.797693 \times 10^{308}.$$

Cualquier número mayor que este conllevaría la parada de cálculos por la incapacidad del equipo para procesarlo. Esto es lo que se denomina un **desbordamiento por exceso** u **overflow**.

**Ejemplo 31** Representemos el número 5.5 como número flotante tanto de precisión simple como de precisión múltiple. En primer lugar, debemos traducir el número 5.5 al sistema binario:

$$5.5 = 4 + 1 + \frac{1}{2} = 2^2 + 2^0 + 2^{-1} = (101.1)_2$$

#### PARTE ENTERA

$$\begin{array}{rcll} & 5 & \underline{2} & \\ (3er \text{ Dígito}) \rightarrow & 1 & 2 & \underline{2} \\ & (2do \text{ Dígito}) \rightarrow & 0 & 1 \leftarrow (1er \text{ Dígito}) \end{array}$$

**PARTE DECIMAL:**  $0.5 \times 2 = 1 \leftarrow (1er \text{ Dígito})$

Como queremos normalizar la expresión escribiendo solo un dígito en la parte entera y que ese dígito sea 1, entonces debemos sacar factor común la mayor potencia de

dos en la expresión del número. En nuestro ejemplo, debe sacarse  $2^2$  como factor común, obteniendo:

$$5.5 = 2^2(2^0 + 2^{-2} + 2^{-3}) = (1.011)_2 \times 2^2.$$

En el caso de trabajar con precisión simple, la expresión del exponente es  $c - 128 = 2$ , con lo que la característica resulta ser  $c = 130$ , que expresado en binario resulta ser  $c = 10000010_2$ ; mientras que la mantisa proviene de la parte decimal  $011$  completándola hasta alcanzar un total de 23 bits:  $01100000000000000000000_2$ . La representación resulta ser:

0 10000010 011000000000000000000000.

[illegible]

0 10000000010 0110000000000000000000000000000000000000000000000000.

**Ejemplo 32** Repetimos el procedimiento pero ahora vamos a considerar un número fraccionario que no va a poder ser expresado de manera exacta usando precisión simple (ni siquiera doble). Consideremos el número 0.1 en decimal. Si calculamos su descomposición en base 2, tenemos:

$$\begin{array}{ll} 0.1 \times 2 = 0.2 & \Rightarrow \text{1er Decimal} = 0 \\ 0.2 \times 2 = 0.4 & \Rightarrow \text{2do Decimal} = 0 \\ 0.4 \times 2 = 0.8 & \Rightarrow \text{3er Decimal} = 0 \\ 0.8 \times 2 = 1.6 & \Rightarrow \text{4o Decimal} = 1 \\ 0.6 \times 2 = 1.2 & \Rightarrow \text{5o Decimal} = 1 \\ 0.2 \times 2 = 0.4 & \Rightarrow \text{6o Decimal} = 0 \quad (\text{Mismo cálculo que 2do decimal: PERIÓDICO}) \end{array}$$

De este modo, el número 0.1 puede expresarse como

$$0.1 = (\widehat{0.00011})_2 = (\widehat{1.1001})_2 \times 2^{-4}$$

Por tanto, la mantisa vendría dada por  $10011001100110011001101_2$ . Observa que el decimal en la posición 23 debería ser un 0 y no un 1, pero los equipos redondean y no truncan, por lo que al ser el decimal 24 igual a 1, entonces hay que redondear por exceso el decimal 23.

Finalmente estudiamos la precisión de la máquina al trabajar con precisión doble en números en punto flotante. Para determinar la **precisión de la máquina** o **precisión epsilon-máquina**, calculamos el error relativo entre 1 y el menor número positivo mayor que 1 en punto flotante. En vista de que estamos calculando el error relativo de una aproximación de 1, el error relativo coincide con el error absoluto. Por tanto, la precisión de la máquina se reduce a calcular la diferencia entre 1 y el menor número positivo mayor que 1 en punto flotante. Obviamente, el menor número positivo mayor que 1 consistiría en sumarle a 1 la potencia  $1^{-52}$  (que es la potencia más pequeña que aparece en la mantisa). De este modo, el número es  $1 + \frac{1}{2^{52}}$  y la precisión buscada es  $\frac{1}{2^{52}} \approx 2.22 \times 10^{-16} < 5 \times 10^{-16}$ . Por tanto, la precisión es 16.

## 9.2. Aritmética con números en punto flotante

Con el fin de simplificar notaciones y conceptos, no trabajaremos números en punto flotante “per se”, sino sus representaciones decimales normalizadas:

$$x = 0.d_1d_2 \cdots d_k d_{k+1} \cdots \times 10^n, \quad 1 \leq d_1 \leq 9, \quad 0 \leq d_i \leq 9.$$

La **representación con  $k$  cifras decimales** de dicho número será la aproximación  $f_1(x)$  obtenida al despreciar los decimales de la mantisa de  $x$  posteriores a la posición decimal  $k$ -ésima:

- **Por truncamiento**, la aproximación sería  $f_1(x) = 0.d_1d_2 \cdots d_k \times 10^n$ , con error relativo:

$$\begin{aligned} \frac{|x - f_1(x)|}{|x|} &= \frac{0.d_1d_2 \cdots d_k d_{k+1} \cdots \times 10^n - 0.d_1d_2 \cdots d_k \times 10^n}{0.d_1d_2 \cdots \times 10^n} \\ &= \frac{0.d_{k+1} \cdots \times 10^{n-k}}{0.d_1d_2 \cdots \times 10^n} = \frac{0.d_{k+1} \cdots}{0.d_1d_2 \cdots} \times 10^{-k} \leq 10^{-k+1}. \end{aligned}$$

- **Por redondeo**, la aproximación  $f_1(x)$  obtenida tendrá un límite superior de error relativo igual a  $5 \times 10^{-k}$ , usando un razonamiento análogo al empleado en la aproximación por truncamiento.

Cuando las operaciones que se van a realizar se llevan a cabo empleando una expresión con  $k$  cifras decimales como la anterior para cada uno de los números involucrados (obviamente, cada uno podría tener una potencia distinta de 10 y ser de magnitud diferente) y los resultados de cada operación binaria se escriben utilizando también la representación con  $k$  cifras decimales, diremos que estamos utilizando una **aritmética con  $k$  cifras significativas**. Dicha aritmética podrá ser por truncamiento o por redondeo, dependiendo de cuál de las dos formas anteriores determinamos el último decimal que se indica.

Se denomina aritmética con cifras significativas porque los errores absolutos obtenidos para la expresión de  $f_1(x)$  tanto por redondeo como por truncando tienen a  $5 \times 10^{-k}$  como límite superior del error relativo, por lo que podemos asegurar que la aproximación  $f_1(x)$  tiene al menos  $k$  cifras significativas en su expresión decimal. Por lo general, abreviaremos diciendo que utilizaremos aritmética de  $k$  cifras y obviaremos la palabra significativa, aunque haremos uso de ella para determinar cuál será la expresión que usaremos en las operaciones.

En la práctica, no es necesario obtener la representación decimal del número exacto  $x$  escrita con parte entera 0 y multiplicada por una potencia (positiva o negativa) de 10, sino que podemos determinar las  $k$  cifras significativas directamente de la expresión decimal habitual. Bastará con considerar las primeras  $k$  cifras de la expresión decimal habitual a partir de la primera no nula (precisamente, es la posición de la primera no nula la que determina la potencia de 10 que aparecía en la expresión indicada al principio de esta subsección).

**Ejemplo 33** Consideremos el número  $x = \sqrt{2}$ , cuya expresión decimal sería 1.414213562373..., que escrita usando potencias de 10 sería  $0.1414213562373... \times 10^1$ .



Su representación con 7 cifras decimales sería  $f_{1R}(x) = 0.1414214 \times 10^1$  por redondeo o  $f_{1T}(x) = 0.1414213 \times 10^1$  por truncamiento. Por tanto, lo que estamos considerando son la aproximación  $x_R = 1.414214$  por redondeo y la aproximación  $x_T = 1.414213$  por truncamiento. Es decir, hemos tomado las primeras 7 cifras no nulas a partir de la primera no nula (el 1) de la expresión decimal habitual de  $x$ .

**Ejemplo 34** Usaremos la aritmética con 5 cifras con redondeo y truncamiento para calcular  $\sqrt{3} + \frac{1}{6} - \frac{2}{5}$ . Para ello, primero necesitaremos conocer la expresión decimal de cada sumando por lo menos en sus primeras 6 cifras no nulas (una más de las que necesitamos para saber cómo hemos de redondear). En el caso que nos ocupa, tenemos:

$$\sqrt{3} \equiv 1.73205... \quad \frac{1}{6} \equiv 0.166666... \quad \frac{2}{5} = 0.4$$

Si usamos la aritmética de 5 cifras con redondeo, entonces tendremos que emplear las siguientes aproximaciones con 5 cifras significativas:

$$\sqrt{3} \approx 1.7321 \quad \frac{1}{6} \approx 0.16667 \quad \frac{2}{5} \approx 0.40000$$

Observa que cogemos las primeras 5 cifras no nulas de la expresión decimal: puede que cuente la parte entera como en el caso de  $\sqrt{3}$  que tiene parte entera no nula o puede que la parte entera sea cero y, por tanto, no correspondería a una cifra significativa (como pasa con los otros dos sumandos). Además, puede ocurrir que el número considerado sea un decimal exacto y, tras la primera cifra no nula en la expresión decimal, “no” hayan suficientes cifras para considerar el número de cifras que nos piden para la aritmética. Eso no es problema porque en la parte decimal puedes añadir tantos ceros a la derecha como estimes oportuno y el número seguirá siendo el mismo. Esto es precisamente lo que pasa con  $\frac{2}{5}$ .

Ahora procedemos a realizar la suma. Tendremos que emplear la asociativa (y a ser posible usando el orden que empleará la máquina) ya que tenemos que aplicar la aritmética de 5 cifras a cada resultado parcial obtenido (concretamente los pasos (1) y (2)):

$$\begin{aligned} \sqrt{3} + \frac{1}{6} - \frac{2}{5} &= \left( \sqrt{3} + \frac{1}{6} \right) - \frac{2}{5} \approx (1.7321 + 0.16667) - 0.40000 \\ &= 1.89877 - 0.40000 \underbrace{\approx}_{(1)} 1.8988 - 0.40000 = 1.4988 \underbrace{\approx}_{(2)} 1.4988 \end{aligned}$$

Si repetimos todo el proceso usando la aritmética de 5 cifras con truncamiento, tendríamos las siguientes aproximaciones de los sumandos:

$$\sqrt{3} \approx 1.7320 \quad \frac{1}{6} \approx 0.16666 \quad \frac{2}{5} \approx 0.40000$$

lo que nos llevaría al siguiente resultado, repitiendo todo el procedimiento y aplicando la aritmética de 5 cifras en cada cálculo intermedio (pasos (1) y (2)):

$$\begin{aligned} \sqrt{3} + \frac{1}{6} - \frac{2}{5} &= \left( \sqrt{3} + \frac{1}{6} \right) - \frac{2}{5} \approx (1.7320 + 0.16666) - 0.40000 \\ &= 1.89866 - 0.40000 \underbrace{\approx}_{(1)} 1.8986 - 0.40000 = 1.4986 \underbrace{\approx}_{(2)} 1.4986 \end{aligned}$$

### 9.3. Problemas computacionales con aritmética en punto flotante

A continuación, indicaremos algunas de las dificultades computacionales que surgen al considerar aproximaciones numéricas (las cuales tomaremos como dadas en punto flotante). Dichas problemáticas son referentes a cancelaciones producidas entre dos expresiones distintas pero que dan como resultado la misma aproximación numérica.

- Errores resultantes de restar dos números prácticamente idénticos:  $x$  e  $y$  dos números reales con  $x > y$  y con representaciones en punto flotante de  $k$  cifras:

$$f1(x) = 0.d_1d_2 \cdots d_p\alpha_{p+1}\alpha_{p+2} \cdots \alpha_k \times 10^n$$

$$f1(y) = 0.d_1d_2 \cdots d_p\beta_{p+1}\beta_{p+2} \cdots \beta_k \times 10^n.$$

La representación de la diferencia  $x - y$  es:

$$f1(f1(x) - f1(y)) = 0.\gamma_{p+1}\gamma_{p+2} \cdots \gamma_k \times 10^{n-p},$$

donde  $\gamma_{p+1}\gamma_{p+2} \cdots \gamma_k = \alpha_{p+1}\alpha_{p+2} \cdots \alpha_k - \beta_{p+1}\beta_{p+2} \cdots \beta_k$ .

Esta representación tendrá, a lo sumo,  $k - p$  cifras, con lo que todos los cálculos posteriores en los que aparezca  $x - y$  contarán con una precisión de solo  $k - p$  cifras (que obviamente es una precisión menor que la precisión original). Esto llevaría al siguiente caso crítico: ¿qué pasaría si los  $k$  primeros decimales de  $x$  e  $y$  son iguales? Pues tendríamos que la diferencia  $x - y$  sería una aproximación de 0 y los cálculos siguientes no serían de utilidad pues estaríamos considerando un número no nulo como si del cero se tratase.

- Propagación del error debida a dividir por número con valor absoluto muy pequeño o a multiplicar por número con valor absoluto muy grande. Veamos que pasaría si cogemos una aproximación  $x^*$  tal que  $|x^*| \leq 10^{-n}$  con  $n \in \mathbb{N}$  suficientemente grande. Si tomamos otra aproximación  $y^*$  de  $y$ , tenemos que  $y = y^* \pm E_A(y)$ . Por tanto, dividir por  $x^*$  correspondería a considerar:

$$\frac{y}{x^*} = \frac{y^*}{x^*} \pm \frac{E_A(y)}{x^*} \longrightarrow E_A\left(\frac{y}{x^*}\right) = \left|\frac{y - y^*}{x^*}\right| = \frac{E_A(y)}{|x^*|} \geq E_A(y) \times 10^n.$$

Es decir, el error de dividir por  $x^*$  correspondería a multiplicar por una potencia muy grande de 10 el error original cometido por la aproximación  $y^*$  de  $y$ . Por tanto, aunque el error absoluto inicial sea muy pequeño, todos los cálculos siguientes a la división corresponderán a errores absolutos bastante elevados.

- Problemas de propagación del error con polinomios: Dependiendo de cómo se expresa la fórmula de resolución de una ecuación de segundo grado, veremos que se puede aplicar correctamente aproximaciones numéricas para obtener sus soluciones o no (por ejemplo, una solución es racionalizar el numerador para la raíz negativa del discriminante de la ecuación). Otro problema que trabajaremos será estudiar cómo las expresiones anidadas de polinomios reducen los errores (absolutos y relativos) cometidos.

**Ejemplo 35** Calcula las soluciones de la ecuación  $x^2 - 10^6x + 1 = 0$ . Si aplicamos la fórmula de la ecuación de segundo grado a esta ecuación, obtendríamos (despreciando unidades)

$$x = \frac{10^6 \pm \sqrt{10^{12} - 4}}{2} \approx \frac{10^6 \pm 10^6}{2} \longrightarrow \begin{cases} x_1 = 10^6 \\ x_2 = 0 \end{cases}$$

La segunda solución conlleva la pérdida de cifras significativas y la consecuente cancelación de las cantidades, pese a que realmente ambos valores no son iguales y no deberían cancelarse. Racionalicemos el numerador para la segunda solución de la ecuación:

$$\begin{aligned} x &= \frac{10^6 - \sqrt{10^{12} - 4}}{2} = \frac{10^6 - \sqrt{10^{12} - 4}}{2} \cdot \frac{10^6 + \sqrt{10^{12} - 4}}{10^6 + \sqrt{10^{12} - 4}} \\ &= \frac{(10^6 - \sqrt{10^{12} - 4}) \cdot (10^6 + \sqrt{10^{12} - 4})}{2(10^6 + \sqrt{10^{12} - 4})} = \frac{(10^6)^2 - (10^{12} - 4)}{2(10^6 + \sqrt{10^{12} - 4})} \\ &= \frac{4}{2(10^6 + \sqrt{10^{12} - 4})} = \frac{2}{10^6 + \sqrt{10^{12} - 4}} \approx \frac{2}{10^6 + \sqrt{10^{12}}} = 10^{-6}. \end{aligned}$$

**Ejemplo 36** Consideremos la función  $f(x) = \sqrt{x+1} - \sqrt{x}$  para  $x \in \mathbb{R}^+$ . Cuando consideramos  $x$  suficientemente grande, tenemos problemas para calcular el valor de  $f(x)$ , porque  $x+1$  se podría aproximar por  $x$  y por lo tanto  $f(x)$  saldría igual a 0. Para poder obtener una aproximación numérica del resultado de esta función para cualquier valor de  $x \in \mathbb{R}^+$ , deberíamos considerar la siguiente manipulación algebraica:

$$\begin{aligned} f(x) &= \sqrt{x+1} - \sqrt{x} = (\sqrt{x+1} - \sqrt{x}) \cdot \frac{\sqrt{x+1} + \sqrt{x}}{\sqrt{x+1} + \sqrt{x}} \\ &= \frac{x+1-x}{\sqrt{x+1} + \sqrt{x}} = \frac{1}{\sqrt{x+1} + \sqrt{x}} \end{aligned}$$

**Ejemplo 37** Sea el polinomio  $P(x) = 2 + 5x - 4x^2 + 3x^3 - 5x^4 + 7x^5$ . Teniendo en cuenta que la potencia  $x^k$  con  $k \in \mathbb{Z}$  puede interpretarse como  $k-1$  productos (bien de  $x$  si  $k \in \mathbb{N}$  o bien de  $\frac{1}{x}$  si  $-k \in \mathbb{N}$ ). Para el polinomio que nos ocupa, tenemos el siguiente número de productos:

$$1 + 2 + 3 + 4 + 5 = 15.$$

Además, tenemos que el número de sumas es 5 para este polinomio.

A medida que el número de operaciones que se realizan aumentan, también aumentarán los errores que se cometen por las aproximaciones. Debe tenerse en cuenta que si conseguimos reducir el número de operaciones a realizar, también habremos reducido los errores de cálculo que se cometen. Esto se puede hacer de las siguientes dos maneras.

La primera consistiría en utilizar las potencias ya calculadas para obtener las que faltan. Así, tendríamos que

$$x^2 = x \cdot x; \quad x^3 = x^2 \cdot x; \quad x^4 = x^3 \cdot x; \quad x^5 = x^4 \cdot x.$$

De este modo, por cada sumando, solo tendríamos que añadir el producto del coeficiente por el monomio y, para las potencias de grado mayor que 1, un producto correspondiente al cálculo de la potencia empleando el mecanismo anteriormente indicado. Por tanto, mientras que el número de sumas permanece siendo el mismo, el de productos disminuye y pasa a ser:

$$1 + 2 + 2 + 2 + 2 = 9.$$

La segunda se basa en escribir el polinomio de forma anidada. Para ello, se sacaría, en la medida de lo posible, la variable  $x$  como factor común. En el ejemplo que nos ocupa, consistiría en escribir el polinomio como:

$$\begin{aligned} P(x) &= 2 + x \cdot (5 - 4x + 3x^2 - 5x^3 + 7x^4) = 2 + x \cdot (5 + x \cdot (-4 + 3x - 5x^2 + 7x^3)) \\ &= 2 + x \cdot (5 + x \cdot (-4 + x \cdot (3 - 5x + 7x^2))) = 2 + x \cdot (5 + x \cdot (-4 + x \cdot (3 + x \cdot (-5 + 7x)))) \end{aligned}$$

De este modo, el número de productos que aparecen en la expresión del polinomio correspondería a añadir solo 1 operación por cada aparición de la variable  $x$ . Como solo aparece 5 veces dicha variable, entonces el número de productos es 5 mientras que el de sumas permanece inalterado. Obviamente, la última expresión del polinomio es la que menor número de operaciones presenta y, por tanto, la que menor error va a propagar.

## 10. Estabilidad y condicionamiento

Cuando se comete un error en una operación (bien por considerar una aproximación bien por operar con una aritmética basada en un determinado número de cifras), dicho error afecta a todos los cálculos posteriores. Por tanto, es necesario conocer cómo el error cometido en un estadio computacional es propagado a estadios sucesivos. Para cuantificar la propagación del error en dichas expresiones, se hace uso de dos conceptos: la estabilidad y el condicionamiento de la expresión algebraica o, más generalmente, del método numérico.

El concepto de condición persigue comparar cuantitativamente la precisión del resultado de realizar una operación con una aproximación respecto de la precisión que presentaba la aproximación usada en los cálculos. Con lo cual, estamos hablando de comparar dos errores relativos y decir si son iguales o si alguno es mayor que el otro. Esto se puede hacer usando cocientes. De este modo, dada una función  $f : \mathbb{R} \rightarrow \mathbb{R} : x \mapsto f(x)$ , consideramos el cociente entre los errores relativos para las aproximaciones de  $f(x)$  y  $x$ , respectivamente; es decir,

$$C(x) = \frac{E_R(f(x^*))}{E_R(x^*)} \approx \left| x \cdot \frac{f'(x)}{f(x)} \right|,$$

donde la aproximación final solo es posible bajo la hipótesis de que la función  $f$  sea de clase 1 cerca de  $x^*$ .

**Nota 38** Si la función es de clase 1 en un entorno de  $x^*$ , entonces lo será en un intervalo conteniendo el valor aproximado  $x^*$  y el exacto  $x$  (pues estamos considerando una aproximación suficientemente precisa). Por tanto, podemos aplicar el Teorema del Valor Medio para esa función en dicho intervalo, con lo que se obtendría:

$$f(x^*) - f(x) \approx f'(x) \cdot (x^* - x).$$

Dividimos la expresión por los valores exactos  $x$  y  $f(x)$ , con lo que se obtiene:

$$\frac{1}{x} \cdot \frac{f(x^*) - f(x)}{f(x)} \approx \frac{f'(x)}{f(x)} \cdot \frac{x^* - x}{x}.$$

Aplicando valor absoluto a ambos miembros y la definición de error relativo, se tiene

$$\frac{1}{|x|} \cdot E_R(f(x^*)) \approx \left| \frac{f'(x)}{f(x)} \right| \cdot E_R(x^*).$$

**Definición 39** Se denomina **número de condición** de la función  $f$  para la aproximación  $x^*$  al valor  $C(x^*)$  indicado anteriormente.

**Nota 40** Fijado  $x^* \in \mathbb{R}$ , tenemos tres posibles respuestas en función de los valores de  $C(x^*)$ :

$$C(x^*) \begin{cases} \in (0, 1) & \implies \text{Problema bien condicionado.} \\ & \text{(i.e. } E_R(f(x^*)) < E_R(x^*), \text{ el error NO aumenta)} \\ = 1 & \implies \text{Error relativo se mantiene constante.} \\ & \text{(i.e. } E_R(f(x^*)) = E_R(x^*)) \\ \in (1, +\infty) & \implies \text{Problema mal condicionado.} \\ & \text{(i.e. } E_R(f(x^*)) > E_R(x^*), \text{ el error SI aumenta)} \end{cases}$$

**Ejemplo 41** Sea la función  $f(x) = \sqrt{x}$ . Calculamos  $f'(x) = \frac{1}{2\sqrt{x}}$ . El número de condición para  $f$  es igual a

$$C(x) = \left| x \cdot \frac{f'(x)}{f(x)} \right| = \left| x \cdot \frac{\frac{1}{2\sqrt{x}}}{\sqrt{x}} \right| = \left| \frac{x}{2x} \right| = \frac{1}{2}.$$

Por tanto, el error relativo se reduciría al aplicar las operaciones y el problema está bien condicionado.

**Ejemplo 42** Sea la función  $f(x) = x^2 - 1$ . La derivada es  $f'(x) = 2x$ . El número de condición para  $f$  es igual a

$$C(x) = \left| x \cdot \frac{f'(x)}{f(x)} \right| = \left| x \cdot \frac{2x}{x^2 - 1} \right| = \left| \frac{2x^2}{x^2 - 1} \right|.$$

Por tanto, el problema está mal condicionado para  $x \approx \pm 1$ .

La inestabilidad o estabilidad de un método numérico nos indica la sensibilidad que presenta dicho método a los errores de redondeo que se cometerán en las

operaciones que aparecen en él. Una definición intuitiva del concepto de estabilidad-inestabilidad es la que se indica a continuación:

Un método numérico se denomina **estable** cuando pequeñas variaciones en los datos iniciales producen pequeñas variaciones en los resultados finales correspondientes. En cambio, el método se denomina **inestable** cuando pequeñas variaciones en los datos iniciales producen grandes variaciones en los datos finales.

De este modo, mientras que la condición se basa en una comparación de los errores relativos y, por tanto, no se ve afectado por los errores de redondeo (pues su cálculo es teórico), la estabilidad-inestabilidad del método va a depender profundamente de los errores con redondeo.

**Ejemplo 43** En el Ejemplo 36, vimos que realizar las operaciones que indica la función  $f(x) = \sqrt{x+1} - \sqrt{x}$  presentaba cancelaciones no deseadas al realizar la diferencia de las dos raíces. Dichas cancelaciones hacían que el resultado de  $f(x)$  fuese siempre aproximado por 0 para  $x$  grande con lo que conllevaría un error relativo igual a 1 independientemente de la precisión que le diésemos a la aproximación de  $x$ . En efecto, sabemos que  $f(x)$  es distinto de cero para  $x > 0$ . Sin embargo, para  $x$  suficientemente grande, el resultado de aplicar  $f$  a  $x$  usando los redondeos pertinentes en las operaciones, da como resultado  $(f(x))^* = 0$ . Por tanto, el error relativo de la aproximación  $(f(x))^*$  con respecto a su valor exacto  $f(x)$  será:

$$E_R((f(x))^*) = \left| \frac{(f(x))^* - f(x)}{f(x)} \right| = \left| \frac{-f(x)}{f(x)} \right| = 1.$$

En consecuencia, por mucha precisión que introdujésemos en el dato de partida, el resultado final carecería de precisión. Es decir, el método para calcular  $f(x)$  es inestable.

No obstante, la expresión  $f(x)$  está bien condicionada para  $x > 0$ :

$$\begin{aligned} C(f(x^*)) &= \left| x \cdot \frac{f'(x)}{f(x)} \right| = \left| x \cdot \frac{\frac{\sqrt{x}-\sqrt{x+1}}{2\sqrt{x+1}\sqrt{x}}}{\sqrt{x+1}-\sqrt{x}} \right| = \left| x \cdot \frac{-1}{2\sqrt{x+1}\sqrt{x}} \right| \\ &= \frac{x}{2\sqrt{x+1}\sqrt{x}} = \frac{(\sqrt{x})^2}{2\sqrt{x+1}\sqrt{x}} = \frac{1}{2} \cdot \frac{\sqrt{x}}{\sqrt{x+1}} < \frac{1}{2} \end{aligned}$$

$$\text{donde } f'(x) = \frac{1}{2\sqrt{x+1}} - \frac{1}{2\sqrt{x}} = \frac{\sqrt{x} - \sqrt{x+1}}{2\sqrt{x+1}\sqrt{x}}.$$

El crecimiento del error en las etapas de un método viene dado por su expresión a lo largo de las etapas del mismo. Si  $E_0 > 0$  es el error del dato de partida y  $E_n$  el error tras  $n$  operaciones, se dice que el crecimiento del error es **lineal** si  $E_n \approx C \cdot n \cdot E_0$  (para una constante  $C$ ) y **exponencial** si  $E_n \approx C^n \cdot E_0$  (para una constante  $C > 1$ ).

## Bibliografía

BURDEN, R.L. y FAIRES, J.D. Análisis Numérico. Thomson Learning, 2002 (pp. 18–26, 33).

FAIRES, J.D. y BURDEN, R.L. Métodos Numéricos. Thomson, 2004 (pp. 16–28).

VARGAS, M.L. Introducción al Cálculo Numérico. 2000 (pp. 1–8). Disponible en:  
[http://www.dim.uchile.cl/~labma33a/ap\\_numerico.html](http://www.dim.uchile.cl/~labma33a/ap_numerico.html).